EVCOMX × FUNDO DO AMANHÃ × BOOTCAMP DATA SCIENCE 2026

Guia de Análise Exploratória de Dados

Predição de Carga Alta no Forno Elétrico a Arco

Explorando os dados do pátio de metálicos, carregamentos, camadas de sucata e a variável resposta — o primeiro passo para construir um modelo preditivo

1. Contexto: O Problema Industrial **3**
1.1 O Fluxo de Produção 3
1.2 O Que é Carga Alta? 3
1.3 Como as Camadas São Organizadas 4
1.4 Objetivo do Projeto 4
1.5 Os Três Datasets 4
2. Carregamento e Inspeção dos Dados **6**
2.1 Carregando os Três Arquivos 6
2.2 Primeiras Inspeções 6
2.3 Limpeza Básica 7
3. Análise do Dicionário de Materiais **8**
3.1 Visão Geral dos Materiais 8
3.2 Relações entre Propriedades 8
3.3 Classificando os Materiais 9
4. Análise das Camadas e Carregamentos **10**
4.1 Estrutura dos Carregamentos 10
4.2 Distribuição de Peso por Carregamento 10
4.3 Composição por Material 11
4.4 Ordem e Posição das Camadas 11
5. Análise da Variável Resposta **13**
5.1 Distribuição do Evento 13
5.2 Carga Alta por Carregamento 13
5.3 Duração das Paradas 14
6. Cruzando os Dados: Camadas × Carga Alta **15**
6.1 Agregando as Camadas por Corrida 15
6.2 Comparação: Carga Alta vs. Normal 15
6.3 Volume Estimado do Cestão 16
7. Padrões Temporais **17**
7.1 Extraindo Informações Temporais 17
7.2 Carga Alta por Turno e Dia da Semana 17
8. Correlações e Distribuições **18**
8.1 Mapa de Correlações 18
8.2 Distribuições por Classe 18
8.3 Análise Bivariada com a Resposta 19
9. Prompts de IA: Aprofundando a EDA **20**
10. Checklist: O Que Apresentar **22**
10.1 O Que os Avaliadores Querem Ver 22
10.2 Checklist de Entregas 22

1. Contexto: O Problema Industrial

A EVCOMX opera fornos elétricos a arco (FEA) para produzir aço a partir de sucata metálica. O processo começa no **pátio de metálicos**, onde diversos tipos de sucata são organizados em **baias**. Essa sucata é carregada em **cestões** (baskets), seguindo uma montagem em **camadas**, e depois despejada no forno.

1.1 O Fluxo de Produção

Etapa	O que acontece	Dados gerados
Pátio de Metálicos	Sucatas são recebidas, classificadas por tipo e armazenadas em baias	Código do material, baia de origem
Montagem do Cestão	Sucatas são empilhadas em camadas dentro do cestão, seguindo regras de peso e classe	Ordem das camadas, peso por camada, tipo de material
Carregamento no FEA	O cestão é despejado no forno (normalmente 2 cestões + gusa líquido)	Número do carregamento, horário
Fusão (FEA)	Eletrodos elétricos e injetores fundem a sucata	Energia consumida, tempo de fusão
Refino (Forno Panela)	Ajuste de composição química e temperatura	Composição final do aço
Lingotamento Contínuo	Aço líquido é solidificado em tarugos	Especificação do produto

1.2 O Que é Carga Alta?

Quando a sucata carregada excede o nível do forno, a **tampa não fecha corretamente**. Os eletrodos não conseguem descer para formar o arco elétrico, e apenas os injetores (gás natural e oxigênio) trabalham até que o volume reduza. Esse fenômeno é chamado de **"Carga Alta"** e causa:

> **Impactos da Carga Alta**
>
> - **Parada de produção:** segundos a minutos em que os eletrodos ficam inativos
> - **Desperdício de energia:** os injetores são menos eficientes que os eletrodos
> - **Risco de "Efeito Mola":** a sucata comprimida pode se expandir, forçando a tampa
> - **Custo operacional:** cada segundo de parada significa perda de produtividade e aumento no consumo de insumos

1.3 Como as Camadas São Organizadas

O cestão é montado em camadas, e a ordem importa. Materiais são classificados em três categorias de peso:

Classe	Posição	Materiais	Característica
Leve	Base e topo	SHRE, ESPS, CAVA, RETL, PACB, ESBS, MARP, MISS	Baixa densidade, ocupa mais volume por tonelada
Pesado	Meio	GUSS, GUSL, RECA, SUGU, FOFO, 194032, 118441	Alta densidade, compacto
Misto	Camada intermediária	OXIC, MISM, PAEP, MISB, CAFO, ESPR, PAEB	Densidade média, versátil

> **Por que a ordem das camadas importa?**
>
> Materiais **leves** no fundo protegem o piso do forno contra impacto dos materiais pesados. No topo, a camada leve cria um "colchão" que reduz a expansão descontrolada. Materiais **pesados** no meio fornecem massa concentrada. Se essa organização não for respeitada, o risco de carga alta aumenta: materiais leves no meio criam bolsas de ar que expandem ao aquecer.

1.4 Objetivo do Projeto

> **Ao final do bootcamp, o grupo deve:**
>
> **-> Construir um modelo que preveja se um carregamento terá carga alta antes de despejar o cestão no forno**
> **-> Identificar quais características do carregamento mais contribuem para a carga alta**
> **-> Propor recomendações práticas para o pátio de metálicos**
> **-> Quantificar o impacto financeiro de evitar paradas por carga alta**

1.5 Os Três Datasets

O projeto trabalha com três arquivos CSV que se conectam pela coluna `cd_corrida` (código único de cada corrida de aço):

Arquivo	Granularidade	Conteúdo
infos_materiais.csv	1 linha por material	Dicionário de propriedades: energia elétrica (kWh/t), densidade (t/m³) e rendimento metálico (%)
infos_camadas.csv	1 linha por camada	Detalhe de cada camada de cada carregamento: material, peso, baia, horário de consumo

VariavelResposta.csv	1 linha por corrida	Indicador binário de carga alta (por carregamento e geral) e duração da parada em segundos

> **Conexão entre os datasets**
>
> `infos_camadas` se conecta a `VariavelResposta` via `cd_corrida`. O `infos_materiais` se conecta a `infos_camadas` via `cd_codigo_material` (que corresponde à coluna `Metálico`). Para montar a visão completa, será preciso fazer **joins** entre as três tabelas.

2. Carregamento e Inspeção dos Dados

O primeiro passo de qualquer EDA é carregar os dados e inspecionar sua estrutura: quantas linhas, quais colunas, que tipos, onde estão os valores faltantes. Não pule esta etapa — ela evita erros silenciosos nas análises seguintes.

2.1 Carregando os Três Arquivos

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# --- Carregando os tres datasets ---
materiais = pd.read_csv('infos_materiais.csv')
camadas   = pd.read_csv('infos_camadas.csv')
resposta  = pd.read_csv('VariavelResposta.csv')

print(f"materiais:  {materiais.shape[0]} linhas x {materiais.shape[1]} colunas")
print(f"camadas:    {camadas.shape[0]} linhas x {camadas.shape[1]} colunas")
print(f"resposta:   {resposta.shape[0]} linhas x {resposta.shape[1]} colunas")
```

2.2 Primeiras Inspeções

```
# --- Inspecao rapida de cada dataset ---
for nome, df in [('materiais', materiais), ('camadas', camadas), ('resposta', resposta)]:
    print(f"\n{'='*50}")
    print(f"  {nome.upper()}")
    print(f"{'='*50}")
    print(df.info())
    print(f"\nPrimeiras linhas:\n{df.head()}")
    print(f"\nValores nulos por coluna:\n{df.isnull().sum()}")
    print(f"\nEstatisticas descritivas:\n{df.describe()}")

# Investigue: quais colunas vieram com tipo errado?
# Investigue: quais colunas tem valores nulos e o que eles significam?
```

O que procurar nesta etapa

- **Tipos de dados:** colunas numéricas que vieram como texto (especialmente as que usam vírgula como separador decimal)
- **Valores nulos:** onde estão e o que significam — um null em `cd_baia` pode indicar gusa líquido (que não vem de baia)
- **Linhas especiais em infos_materiais:** repare que alguns códigos (7071955, 8800022, 7071940) têm `null` em energia e rendimento — são **insumos** (CAL, COQUE), não materiais metálicos
- **Formato de datas:** `dt_hora_consumo` está em ISO 8601 — converta para datetime

2.3 Limpeza Básica

```
# --- Limpeza basica ---

# 1. Corrigir separador decimal em infos_materiais
#    As colunas numericas usam virgula: "0,40" em vez de "0.40"
#    Dica: releia o CSV com decimal=',' ou converta manualmente:
#    materiais['coluna'] = materiais['coluna'].str.replace(',', '.').astype(float)

# 2. Separar materiais metalicos de insumos
#    Algumas linhas sao insumos (CAL, COQUE), nao sucata metalica
#    Identifique-as: quais linhas tem null em Energia e Rendimento?

# 3. Converter datas
#    camadas['dt_hora_consumo'] = pd.to_datetime(camadas['dt_hora_consumo'])

# 4. Verificar duplicatas
#    camadas.duplicated().sum()
#    resposta.duplicated(subset='cd_corrida').sum()

# 5. Quantas corridas unicas existem em cada dataset?
#    Compare: as corridas de camadas estao todas em resposta?
#    corridas_camadas  = set(camadas['cd_corrida'].unique())
#    corridas_resposta = set(resposta['cd_corrida'].unique())
#    print(f"So em camadas: {len(corridas_camadas - corridas_resposta)}")
#    print(f"So em resposta: {len(corridas_resposta - corridas_camadas)}")
```

> **Cuidado com o separador decimal**
>
> O arquivo `infos_materiais.csv` usa **vírgula** como separador decimal (ex: `"0,40"` para densidade). O pandas não converte isso automaticamente. Use `decimal=','` no `read_csv` ou converta manualmente com `.str.replace(',', '.').astype(float)`.

3. Análise do Dicionário de Materiais

O `infos_materiais.csv` é a "ficha técnica" de cada tipo de sucata. Entender suas propriedades é essencial para interpretar a montagem dos cestões e criar features com significado físico.

3.1 Visão Geral dos Materiais

```
# --- Visao geral dos materiais ---
# Apos corrigir o separador decimal, visualize a tabela completa:

print(materiais.to_string(index=False))

# Investigue:
# - Quantos materiais metalicos existem? E quantos insumos?
# - Qual material tem a MENOR densidade? E a MAIOR?
# - Qual material consome mais energia por tonelada?
# - Ha alguma relacao entre densidade e rendimento metalico?
```

3.2 Relações entre Propriedades

```
# --- Scatter plot: propriedades dos materiais ---
# Sugestao: faca um grafico com Densidade no eixo X,
# Energia Eletrica no eixo Y e Rendimento Metalico como cor.
# Isso revela a "personalidade" de cada tipo de sucata.

# Dica de codigo:
# fig, ax = plt.subplots(figsize=(10, 6))
# scatter = ax.scatter(x=..., y=..., c=..., cmap='RdYlGn', s=100, edgecolors='k')
# for i, row in materiais_metalicos.iterrows():
#     ax.annotate(row['Metalico'], (row['Densidade'], row['Energia']), fontsize=8)
# plt.colorbar(scatter, label='Rendimento Metalico')
# ax.set_xlabel('Densidade (t/m3)')
# ax.set_ylabel('Energia Eletrica (kWh/t)')
# plt.title('Propriedades dos Materiais Metalicos')
# plt.tight_layout()
# plt.show()
```

Interpretando as propriedades

- **Energia Elétrica (kWh/t):** quanta energia o forno precisa para fundir 1 tonelada daquele material. Materiais com alta energia consomem mais recursos
- **Densidade (t/m³):** quanta massa cabe em 1 metro cúbico. Materiais de **baixa** densidade (ex: SHRE 0,70; ESPS 0,40) ocupam muito volume — são eles que mais contribuem para a carga alta
- **Rendimento Metálico (%):** fração do material que vira aço líquido. Rendimento de 93% significa que 7% vira escória ou se perde

3.3 Classificando os Materiais

```
# --- Classificacao por classe de peso ---
# Crie uma coluna 'classe' em materiais usando os grupos abaixo:

leves   = ['SHRE', 'ESPS', 'CAVA', 'RETL', 'PACB', 'ESBS', 'MARP', 'MISS']
pesados = ['GUSS', 'GUSL', 'RECA', 'SUGU', 'FOFO', '194032', '118441']
mistos  = ['OXIC', 'MISM', 'PAEP', 'MISB', 'CAFO', 'ESPR', 'PAEB']

# Dica: use np.select ou um dicionario para mapear cada material
# Depois, agrupe por classe e calcule a media de cada propriedade
# Isso confirma que materiais "leves" tem densidade baixa e
# materiais "pesados" tem densidade alta

# Investigue: a classificacao faz sentido fisico?
# Algum material esta "no limite" entre duas classes?
```

Insight esperado

-> Materiais leves têm densidade baixa (< 0,55 t/m³) e rendimento metálico alto (> 0,90)
-> Materiais pesados têm densidade alta (> 2,50 t/m³) e energia mais elevada
-> A densidade é a propriedade mais diretamente ligada ao risco de carga alta: quanto menor a densidade, mais volume a mesma massa de sucata ocupa no cestão

4. Análise das Camadas e Carregamentos

O dataset `infos_camadas.csv` é o mais rico e detalhado. Cada linha representa uma camada dentro de um carregamento de uma corrida. A estrutura hierárquica é: **Corrida** → **Carregamento** → **Camada**.

4.1 Estrutura dos Carregamentos

```
# --- Estrutura dos carregamentos ---
# Entenda a hierarquia: Corrida -> Carregamento -> Camada

print("Carregamentos por corrida:")
print(camadas.groupby('cd_corrida')['nu_carregamento'].nunique().describe())

print("\nCamadas por carregamento:")
print(camadas.groupby(['cd_corrida', 'nu_carregamento'])['nu_camada'].count().describe())

# Investigue:
# - Todas as corridas tem 3 carregamentos (2 cestos + gusa)?
# - Quantas camadas tem, em media, cada carregamento?
# - O carregamento 3 e sempre GUSL? Verifique.
```

Os três carregamentos

- **Carregamento 1:** primeiro cestão de sucata sólida, despejado no forno vazio
- **Carregamento 2:** segundo cestão de sucata sólida, despejado sobre a carga parcialmente fundida do primeiro
- **Carregamento 3:** gusa líquido (GUSL), adicionado após a fusão dos dois cestões — tipicamente 30-36 toneladas

A **carga alta ocorre nos carregamentos 1 e 2** (sólidos), nunca no 3 (líquido). Por isso a variável resposta tem indicadores separados para cada carregamento.

4.2 Distribuição de Peso por Carregamento

```
# --- Distribuicao de peso por carregamento ---
# Agrupe por corrida e carregamento, some o peso, e visualize

# peso_por_carreg = camadas.groupby(
#     ['cd_corrida', 'nu_carregamento']
# )['qt_peso_carregamento'].sum().reset_index()

# Sugestao de grafico: boxplot do peso total por nu_carregamento
# Isso mostra a variabilidade de peso entre corridas

# Investigue:
# - O carregamento 1 e mais pesado que o 2? Ou o contrario?
# - Qual a faixa tipica de peso total por cesto (em toneladas)?
# - Existem outliers? O que poderiam significar?
```

4.3 Composição por Material

```
# --- Composicao por material ---
# Quais materiais sao mais usados? Em peso e em frequencia?

# Dica: agrupe infos_camadas por cd_codigo_material e calcule:
#   - Peso total por material (soma)
#   - Numero de vezes que aparece (contagem)
#   - Peso medio por camada

# Sugestao de grafico: barplot horizontal do peso total por material
# Ordene do maior para o menor

# Investigue:
# - Qual material contribui mais em peso total?
# - Qual material aparece com mais frequencia?
# - A composicao muda entre carregamento 1 e carregamento 2?
#   Dica: filtre camadas por nu_carregamento e compare
```

Perguntas para investigar

- Quais materiais aparecem com mais frequência? E quais contribuem mais em peso?
- A composição do carregamento 1 é diferente da do carregamento 2?
- Quantas camadas, em média, tem cada carregamento?
- Existem materiais que nunca aparecem juntos no mesmo cestão?

4.4 Ordem e Posição das Camadas

```
# --- Ordem e posicao das camadas ---
# A coluna nu_camada indica a posicao (1 = fundo, ultima = topo)
# Analise se a regra "leve-pesado-leve" esta sendo seguida

# Sugestao: para cada corrida+carregamento, identifique:
#   - Qual material esta na camada 1 (fundo)?
#   - Qual material esta na ultima camada (topo)?
#   - Os materiais pesados estao concentrados no meio?

# Dica: junte com a classificacao de classe (leve/pesado/misto)
# e calcule a posicao relativa de cada classe:
#   camadas['pos_relativa'] = camadas['nu_camada'] / camadas.groupby(
#       ['cd_corrida', 'nu_carregamento']
#   )['nu_camada'].transform('max')

# Investigue:
# - A posicao relativa media dos materiais leves e < 0.3 (fundo)
#   e > 0.7 (topo)? E a dos pesados, fica entre 0.3 e 0.7?
# - Existem corridas onde a regra foi violada?
# - Essas violacoes se correlacionam com carga alta?
```

> **A sequência de montagem importa**
>
> A coluna `nu_camada` indica a ordem em que o material foi colocado no cestão (1 = fundo, última = topo). Analise se os materiais leves estão realmente nas posições de base e topo, e os pesados no meio. **Desvios desse padrão** podem ser preditivos de carga alta.

5. Análise da Variável Resposta

A variável resposta é binária: **houve carga alta ou não**. Entender sua distribuição, a frequência do evento e o impacto associado é fundamental para a modelagem.

5.1 Distribuição do Evento

```
# --- Distribuicao da variavel resposta ---
print("Distribuicao geral de carga alta:")
print(resposta['is_carga_alta'].value_counts())
print(f"\nTaxa de carga alta: {resposta['is_carga_alta'].mean():.1%}")

# Sugestao de grafico: barplot simples com as contagens
# Anote a porcentagem em cada barra

# Investigue:
# - O dataset e desbalanceado? Qual a proporcao?
# - Quantas corridas no total estao disponiveis?
# - Isso e suficiente para treinar um modelo?
```

> **Desbalanceamento de classes**
>
> Se a proporção de carga alta for muito baixa (ex: < 20%), o dataset é **desbalanceado**. Isso afeta diretamente a escolha de métricas e técnicas de modelagem. Na EDA, registre essa proporção — ela será crucial nas próximas etapas.

5.2 Carga Alta por Carregamento

```
# --- Carga alta por carregamento ---
print("Carga alta no carregamento 1:")
print(resposta['is_carga_alta_carregamento_1'].value_counts())
print(f"Taxa: {resposta['is_carga_alta_carregamento_1'].mean():.1%}")

print("\nCarga alta no carregamento 2:")
print(resposta['is_carga_alta_carregamento_2'].value_counts())
print(f"Taxa: {resposta['is_carga_alta_carregamento_2'].mean():.1%}")

# Investigue:
# - Qual carregamento tem mais eventos de carga alta?
# - Existem corridas com carga alta nos DOIS carregamentos?
#   Dica: resposta[(resposta['is_carga_alta_carregamento_1']==1) &
#                  (resposta['is_carga_alta_carregamento_2']==1)]
# - O que isso pode significar do ponto de vista operacional?
```

> **Carregamento 1 vs. Carregamento 2**
>
> O carregamento 1 despeja no forno **vazio** e o carregamento 2 sobre metal já parcialmente fundido. Isso muda a dinâmica: o carregamento 2 tem menos espaço disponível, mas o metal fundido já "absorveu" parte do volume. Compare as taxas de carga alta entre os dois — elas são iguais? Se não, por quê?

5.3 Duração das Paradas

```
# --- Duracao das paradas ---
# Filtre apenas as corridas COM carga alta e analise a duracao

paradas = resposta[resposta['is_carga_alta'] == 1]['qt_segundos_parada_carga_alta']
print(f"Duracao da parada (segundos):")
print(paradas.describe())

# Sugestao de grafico: histograma da duracao das paradas
# Marque a mediana e a media no grafico

# Investigue:
# - Qual a parada mais longa registrada?
# - Qual a mediana (valor tipico)?
# - Calcule o impacto total: soma de todas as paradas em minutos
# - Se cada minuto de parada custa R$ X, qual o custo total?
#   (Discutam com o orientador um valor estimado por minuto)
```

> **O impacto real em números**
>
> **-> Calcule o tempo médio de parada por evento de carga alta**
> **-> Multiplique pelo número de eventos para obter o tempo total perdido**
> **-> Esse número é o argumento central do business case: "se conseguirmos evitar X% dos eventos de carga alta, economizamos Y minutos de produção por mês"**

6. Cruzando os Dados: Camadas × Carga Alta

A análise mais importante desta EDA é **conectar as características do carregamento com a ocorrência de carga alta**. Aqui começamos a responder: o que diferencia um carregamento que causa carga alta de um que não causa?

6.1 Agregando as Camadas por Corrida

```
# --- Agregando camadas por corrida ---
# Para cruzar com a variavel resposta, crie um resumo por corrida.
# Cada corrida deve virar UMA linha com features agregadas.

# Sugestoes de features para agregar (por corrida + carregamento):
#   - peso_total: soma de qt_peso_carregamento
#   - num_camadas: contagem de camadas
#   - num_materiais_distintos: nunique de cd_codigo_material
#   - peso_leve, peso_pesado, peso_misto: peso por classe
#   - prop_leve: peso_leve / peso_total (proporcao de material leve)
#   - volume_estimado: sum(peso / densidade) para cada material

# Dica de estrutura:
# agg = camadas[camadas['nu_carregamento'].isin([1, 2])].groupby(
#     ['cd_corrida', 'nu_carregamento']
# ).agg(...)
# Depois faca um merge com resposta via cd_corrida

# Investigue: quais dessas features voce acha que sao mais
# relevantes para prever carga alta? Por que?
```

> **Features agregadas: do detalhe ao resumo**
>
> Cada corrida tem dezenas de linhas em `infos_camadas`. Para cruzar com a variável resposta (que tem 1 linha por corrida), precisamos **agregar**: peso total, número de camadas, proporção de cada tipo de material, volume estimado, etc. Esse processo é a prévia da Feature Engineering.

6.2 Comparação: Carga Alta vs. Normal

```
# --- Comparacao: carga alta vs. normal ---
# Com o dataframe agregado + resposta, compare as medias

# Dica:
# df_completo.groupby('is_carga_alta')[features_numericas].mean()

# Sugestao de grafico: para cada feature, faca um boxplot
# lado a lado (carga_alta=0 vs carga_alta=1)
# Use subplots para mostrar varias features de uma vez

# Investigue:
# - Quais features tem a MAIOR diferenca entre os dois grupos?
# - Alguma feature surpreende por NAO ser diferente?
# - O volume estimado e realmente diferente? Por quanto?
# - A proporcao de material leve e maior nos casos de carga alta?
```

6.3 Volume Estimado do Cestão

```
# --- Volume estimado do cestao ---
# O volume e a chave: peso / densidade = volume
# Para calcular por corrida, voce precisa do join com materiais

# Ideia:
# 1. Junte camadas com materiais (via cd_codigo_material)
# 2. Calcule volume de cada camada: peso / densidade
# 3. Some por corrida+carregamento para ter o volume total estimado
# 4. Compare a distribuicao do volume entre carga_alta=0 e carga_alta=1

# Sugestao de grafico: histograma sobreposto ou KDE plot
# do volume estimado, colorido por is_carga_alta
# Se as distribuicoes se separam, voce tem uma boa feature!

# Investigue:
# - Existe um "limiar" de volume acima do qual a carga alta
#   quase sempre acontece?
# - Qual a area de sobreposicao entre as distribuicoes?
# - Um modelo simples baseado so no volume teria que acuracia?
```

Insight-chave: volume, não apenas peso

-> O forno tem capacidade volumétrica limitada. Um cestão com 40 toneladas de material denso (GUSS) pode caber, enquanto 35 toneladas de material leve (ESPS, SHRE) podem transbordar

-> O volume estimado (peso / densidade de cada material) é provavelmente a feature mais preditiva para carga alta

-> Compare a distribuição do volume estimado entre corridas com e sem carga alta: ela deve ser claramente diferente

7. Padrões Temporais

Os dados possuem **carimbos de tempo** (`dt_hora_consumo`) que permitem investigar se o comportamento varia ao longo do tempo — por turno, dia da semana ou período.

7.1 Extraindo Informações Temporais

```
# --- Extraindo informacoes temporais ---
# A coluna dt_hora_consumo (apos converter para datetime) contem
# o horario exato de cada operacao de carregamento

# Sugestoes de features temporais:
#   camadas['hora']       = camadas['dt_hora_consumo'].dt.hour
#   camadas['dia_semana'] = camadas['dt_hora_consumo'].dt.dayofweek
#   camadas['mes']        = camadas['dt_hora_consumo'].dt.month

# Defina os turnos da usina (verifique com o orientador):
#   Turno A: 06h-14h | Turno B: 14h-22h | Turno C: 22h-06h
#   Dica: use pd.cut ou np.select para criar a coluna 'turno'

# Para cada corrida, use o horario do PRIMEIRO carregamento
# como referencia temporal da corrida
```

7.2 Carga Alta por Turno e Dia da Semana

```
# --- Carga alta por turno e dia da semana ---
# Com a informacao temporal associada a cada corrida,
# cruze com a variavel resposta

# Sugestao de graficos:
# 1. Barplot: taxa de carga alta por turno
# 2. Barplot: taxa de carga alta por dia da semana
# 3. Lineplot: taxa de carga alta ao longo do tempo (por semana ou mes)

# Investigue:
# - Algum turno tem taxa significativamente diferente?
# - Fins de semana sao diferentes de dias uteis?
# - Existe tendencia temporal (esta melhorando ou piorando)?
# - Se houver diferenca entre turnos, o que poderia explicar?
#   (diferentes equipes, nivel de experiencia, supervisao...)
```

Por que padrões temporais importam?

- **Turnos:** equipes diferentes podem ter práticas diferentes de montagem de cestão
- **Dias da semana:** fins de semana podem ter operação reduzida ou menos supervisão
- **Tendência:** a taxa de carga alta está melhorando ou piorando ao longo dos meses? Houve alguma mudança de processo?

Se encontrarem diferenças significativas, isso sugere que fatores operacionais (não apenas a composição do cestão) influenciam o resultado.

8. Correlações e Distribuições

Com as features agregadas e a variável resposta no mesmo dataframe, podemos calcular correlações e visualizar as distribuições mais relevantes.

8.1 Mapa de Correlações

```
# --- Mapa de correlacoes ---
# Com o dataframe consolidado (features + resposta), calcule
# a matriz de correlacao e visualize como heatmap

# Dica:
# corr = df_completo[features_numericas + ['is_carga_alta']].corr()
# plt.figure(figsize=(12, 10))
# sns.heatmap(corr, annot=True, fmt='.2f', cmap='RdBu_r',
#             center=0, vmin=-1, vmax=1)
# plt.title('Mapa de Correlacoes')
# plt.tight_layout()
# plt.show()

# Investigue:
# - Quais features tem a MAIOR correlacao com is_carga_alta?
# - Quais features sao muito correlacionadas ENTRE SI?
#   (isso indica multicolinearidade - discutam se e problema)
# - O volume estimado confirma ser a variavel mais correlacionada?
```

8.2 Distribuições por Classe

```
# --- Distribuicoes por classe ---
# Para as features mais promissoras, visualize a distribuicao
# separada por carga_alta = 0 vs. carga_alta = 1

# Sugestao: crie um grid de subplots (2x3 ou 3x3) com histogramas
# sobrepostos ou KDE plots para cada feature

# Dica:
# features_top = ['volume_estimado', 'peso_total', 'prop_leve',
#                 'num_camadas', 'peso_leve', 'num_materiais']
# fig, axes = plt.subplots(2, 3, figsize=(15, 10))
# for ax, feat in zip(axes.flat, features_top):
#     for classe, cor in [(0, 'steelblue'), (1, 'tomato')]:
#         subset = df_completo[df_completo['is_carga_alta'] == classe][feat]
#         ax.hist(subset, bins=30, alpha=0.5, color=cor,
#                 label=f'Carga Alta = {classe}')
#     ax.set_title(feat)
#     ax.legend()

# Investigue: em quais features a separacao visual e mais clara?
# Essas sao as candidatas mais fortes para o modelo.
```

O que procurar nos gráficos

- **Separação visual:** se as distribuições de uma feature são claramente diferentes entre carga alta = 0 e carga alta = 1, essa feature é um bom candidato para o modelo
- **Outliers:** valores extremos de peso, número de camadas ou volume podem indicar erros de registro ou situações operacionais atípicas
- **Multicolinearidade:** features muito correlacionadas entre si (ex: peso total e volume estimado) devem ser tratadas na etapa de feature selection

8.3 Análise Bivariada com a Resposta

```
# --- Analise bivariada com a resposta ---
# Aprofunde a relacao entre cada feature e carga alta

# Sugestao 1: Violin plot ou swarm plot para features continuas
# Sugestao 2: Tabela cruzada para features categoricas (turno, classe)
# Sugestao 3: Point-biserial correlation para quantificar

# Dica para calcular a correlacao point-biserial:
# from scipy.stats import pointbiserialr
# for feat in features_numericas:
#     corr, pval = pointbiserialr(df_completo['is_carga_alta'], df_completo[feat])
#     print(f"{feat:30s} corr={corr:+.3f}  p={pval:.4f}")

# Investigue:
# - Quais features sao estatisticamente significativas (p < 0.05)?
# - A magnitude da correlacao faz sentido com o que voce viu
#   nos graficos?
# - Salve o dataframe consolidado para a proxima etapa:
#   df_completo.to_csv('dataset_modelagem.csv', index=False)
```

9. Prompts de IA: Aprofundando a EDA

Use estes prompts para aprofundar o entendimento e obter insights adicionais. Cole os dados reais do grupo entre colchetes [ ].

Prompt 1 — Entender o Processo Industrial

Sou estudante de Data Science e estou num projeto de predição de "carga alta" em forno elétrico a arco (FEA) para produção de aço. A carga alta ocorre quando a sucata ultrapassa o nível do forno e a tampa não fecha.

Me explique de forma prática:

1. Por que a ordem das camadas de sucata no cestão importa para evitar carga alta?
2. Qual a relação entre densidade do material e volume ocupado no forno?
3. Por que o carregamento 3 (gusa líquido) não causa carga alta?
4. O que é o "efeito mola" e por que é perigoso?
5. Que fatores operacionais (além da composição) podem influenciar a carga alta?

Prompt 2 — Interpretar a EDA dos Materiais

Analisei o dicionário de materiais do forno e construí um scatter plot de energia (kWh/t) vs. densidade (t/m³) com rendimento metálico como cor. Resultados:

[Cole aqui: tabela do `infos_materiais` e uma descrição do gráfico]

1. Que padrões você vê entre os materiais leves e pesados?
2. Existe um trade-off entre densidade e rendimento metálico?
3. Quais materiais são os mais "problemáticos" do ponto de vista de carga alta e por quê?
4. Se pudesse escolher apenas 5 features do dicionário de materiais para usar no modelo, quais escolheria?

Prompt 3 — Interpretar o Cruzamento Camadas × Carga Alta

Cruzei os dados de camadas agregados com a variável resposta. As features que mais diferenciaram corridas com e sem carga alta foram:

[Cole aqui: tabela comparativa com médias das features agrupadas por `is_carga_alta`]

1. Essas diferenças fazem sentido do ponto de vista físico?
2. Alguma variável me surpreenderia como **não** sendo significativa?
3. Que interações entre features você sugeriria investigar?
4. Como explicar para um engenheiro de processo que "volume estimado é mais preditivo que peso total"?

Prompt 4 — Analisar Padrões Temporais

Encontrei variação na taxa de carga alta entre turnos e dias da semana. Os dados mostram:

[Cole aqui: tabela com taxa de carga alta por turno e por dia da semana]

1. Essas diferenças são estatisticamente significativas ou podem ser ruído?
2. Que hipóteses operacionais explicariam a variação por turno?
3. Devo incluir o turno/dia como feature no modelo ou isso seria data leakage?
4. Como testar se houve uma mudança de processo ao longo do tempo?

Prompt 5 — Preparar a Narrativa da EDA

Concluí a EDA dos dados de carregamento de sucata em forno elétrico a arco. Principais achados:

[Descreva seus 3-5 principais insights aqui]
Exemplo: “a taxa de carga alta é de X%, mais frequente no carregamento Y; o volume estimado é Z% maior nas corridas com carga alta; o material W aparece 3x mais em corridas problemáticas...”

1. Sugira uma narrativa de 3 atos para a apresentação da EDA.
2. Quais dos meus insights são mais surpreendentes para um engenheiro de processo?
3. Que perguntas a banca provavelmente vai fazer e como responder?
4. Quais são os 5 gráficos mais importantes para incluir nos slides?

10. Checklist: O Que Apresentar

A apresentação desta etapa deve mostrar que o grupo **entende o processo industrial**, explorou os dados com profundidade e sabe exatamente o que alimentará o modelo.

10.1 O Que os Avaliadores Querem Ver

Critério	O que demonstrar
Conhecimento do domínio	Explicar o processo FEA, o que é carga alta, por que importa e como a montagem do cestão influencia
Qualidade da EDA	Gráficos claros e informativos; investigação de missing values, outliers e dados inconsistentes
Conexão dados → física	Volume estimado vs. peso; por que densidade importa mais que massa; ordem das camadas
Visão crítica	Identificar limitações dos dados, desbalanceamento, e possíveis viéses
Preparação para modelagem	Mostrar que as features criadas têm poder discriminatório e justificar quais entrarão no modelo

10.2 Checklist de Entregas

Dados

- Três datasets carregados e inspecionados (tipos, nulls, duplicatas)
- Separadores decimais corrigidos em `infos_materiais`
- Datas convertidas para datetime
- Joins entre datasets realizados e validados

Materiais

- Tabela de propriedades visualizada (energia, densidade, rendimento)
- Scatter plot de propriedades com classificação por classe de peso
- Identificação dos insumos (CAL, COQUE) vs. materiais metálicos

Camadas e Carregamentos

- Distribuição de peso por carregamento e por material
- Número de camadas por carregamento
- Padrão de montagem: quais materiais nas posições de base, meio e topo
- Diferenças entre carregamento 1 e carregamento 2

Variável Resposta

- Taxa de carga alta geral e por carregamento
- Distribuição da duração das paradas (histograma, mediana, percentis)
- Identificação de desbalanceamento de classes

Cruzamentos

- Features agregadas por corrida (peso total, volume estimado, nº camadas, proporção por classe)
- Comparação: médias das features em corridas com vs. sem carga alta
- Volume estimado como principal fator discriminante
- Mapa de correlações entre features agregadas e a resposta

Temporal e Insights

- Taxa de carga alta por turno, dia da semana e ao longo do tempo
- Top 5 insights documentados e justificados
- Dataset final consolidado salvo em CSV para a etapa de modelagem

> **Dica Final — Conte a história do aço**
>
> Não mostrem gráficos um por um como uma lista de códigos. Construam uma narrativa:
>
> **"Analisamos [N] corridas de aço com [M] camadas de sucata. Descobrimos que a carga alta ocorre em [X]% dos carregamentos e causa [Y] minutos de parada por mês. O principal fator não é o peso total, mas o *volume estimado* do cestão: corridas com carga alta têm volume [Z]% maior. Materiais leves como [A] e [B] são os que mais contribuem. Além disso, encontramos diferenças entre turnos, o que sugere que fatores operacionais também importam."**
>
> Isso mostra entendimento do processo industrial, não apenas execução técnica. Bom trabalho!