BOOTCAMP DATA SCIENCE

Resumo & Guia Prático — Aula III

Visualização de Dados

Pré-processamento · EDA · Correlação · Python · Prompts de IA

08 de maio de 2026 | Fabricio Leal

Material de apoio — uso exclusivo dos alunos

1. Introdução — Por que Visualização de Dados é tão Importante? **3**
2. Tipos e Formatos de Dados **3**
2.1 Tipos de Dados 3
2.2 Formatos de Dados 4
4. Análise Univariada — Explorando Cada Variável **7**
4.1 Variáveis Numéricas 7
4.2 Variáveis Categóricas 7
5.1 Correlação de Pearson — Teoria 8
5.2 Código — Matriz de Correlação Completa 8
5.3 Scatter Plot e Pairplot 9
5.4 Comparação por Grupos 10
6.1 Configurações de Estilo Profissional 11
7.1 Entendimento dos Dados 12
7.2 Tratamento de Dados 13
7.3 Visualização e Interpretação 13
7.4 Criação do Manual de Identidade Visual (MIV) 14
8. Bases de Dados para Praticar **15**
8.1 Datasets Clássicos para Iniciantes 15
8.2 Bases de Dados Brasileiras Públicas 15
9. Ferramentas e Recursos Essenciais **17**
9.1 Bibliotecas Python para EDA 17
9.2 Sites e Recursos Indicados na Aula 17
10. Boas Práticas de Visualização de Dados **18**
10.1 O Princípio Fundamental 18
10.2 Regras de Ouro do Design 18
10.3 O que NUNCA fazer 19
11. Checklist — Análise Exploratória para a Próxima Aula **20**
✅ Fase 1 — Preparação dos Dados 20
✅ Fase 2 — Análise Univariada 20
✅ Fase 3 — Análise Bivariada 20
✅ Fase 4 — Apresentação 20
12. Glossário de Termos **22**
13. Tarefa para a Próxima Aula **23**
14. Referências Bibliográficas 23

1. Introdução — Por que Visualização de Dados é tão Importante?

A Aula III abriu com uma das reflexões mais importantes do bootcamp: na prática real de mercado, a maior parte do esforço de um cientista de dados não está nos algoritmos, mas nos dados em si.

> 📊 **A Regra dos 80/20 em Data Science**
> **~80%** do trabalho: exploração, limpeza, transformação e visualização dos dados.
> **~20%** do trabalho: seleção de algoritmo, treinamento e avaliação do modelo.
>
> Isso significa que dominar visualização de dados é o que diferencia um bom cientista de dados
> de alguém que apenas roda algoritmos sem entender o que está acontecendo com os dados.

Além disso, um ponto crucial levantado na aula: quando você vai a uma empresa para desenvolver um projeto de Data Science, a realidade frequentemente é diferente do esperado. Os dados podem estar incompletos, mal formatados, desatualizados ou simplesmente não existir. Por isso, saber explorar e visualizar dados é uma habilidade de sobrevivência no mercado.

2. Tipos e Formatos de Dados

2.1 Tipos de Dados

Tipo	Descrição	Exemplos
Observacional	Capturado em tempo real. Não pode ser recriado.	Sensores IoT, pesquisas, imagens de câmera, telemetria
Experimental	Gerado em condições controladas. Reproduzível, mas pode ser caro.	Testes A/B, experimentos de laboratório, ensaios clínicos
Derivado / Compilado	Gerado a partir de dados existentes. Inclui upsampling.	Mineração de texto, bases financeiras, SMOTE, modelos 3D
Simulado	Gerado por modelos computacionais.	Modelos climáticos, tráfego, simulações econômicas

2.2 Formatos de Dados

Formato	Características	Ferramentas Comuns
Estruturado	Linhas e colunas bem definidas. Fácil leitura por máquina.	SQL, Excel, pandas DataFrame, ERPs
Não Estruturado	Sem organização predefinida. Requer mais processamento.	NLTK, OpenCV, Whisper, BeautifulSoup
Semiestruturado	Alguma estrutura, mas não tabular. Conversível para estruturado.	JSON, XML, CSV, HTML — pandas, json, lxml

> ⚠️ **Caso Real — Problema de Delimitador (RAIS/CAGED)**
>
> Durante a semana, a equipe tentou trabalhar com a base RAIS dos últimos 15 anos no RS.
> Ao chegar em arquivos anteriores a 2021, cabeçalhos corrompidos e delimitadores
> misturados inviabilizaram a leitura direta. Validação de cabeçalho e delimitador é obrigatória antes de qualquer processamento, mesmo em bases de fontes oficiais.

3. Pré-processamento dos Dados — Guia Passo a Passo

O pré-processamento é a etapa que garante que seus dados estão prontos para análise. Siga os passos abaixo em ordem:

1 **Carregue e inspecione o arquivo**

Verifique se o arquivo carrega corretamente, identifique o delimitador, o encoding e se o cabeçalho está presente.

```
import pandas as pd

# Carregar o arquivo
df = pd.read_csv('seu_arquivo.csv', sep=';', encoding='utf-8')

# Primeiras linhas
df.head(10)

# Dimensões: (linhas, colunas)
```

```
print(f'Shape: {df.shape}')

# Tipos de cada coluna
print(df.dtypes)

# Informações gerais (nulos, tipos, memória)
df.info()
```

2 Verifique valores ausentes (Missing Values)

Identifique quais colunas têm dados faltando e qual o percentual de ausência.

```
# Quantidade de nulos por coluna
nulos = df.isnull().sum()
print(nulos[nulos > 0])

# Percentual de nulos
pct_nulos = (df.isnull().sum() / len(df) * 100).round(2)
print(pct_nulos[pct_nulos > 0].sort_values(ascending=False))

# Heatmap de dados ausentes (requer seaborn e matplotlib)
import seaborn as sns
import matplotlib.pyplot as plt

plt.figure(figsize=(12, 6))
sns.heatmap(df.isnull(), cbar=False, cmap='viridis', yticklabels=False)
plt.title('Mapa de Valores Ausentes')
plt.tight_layout()
plt.savefig('missing_values.png', dpi=150)
plt.show()
```

💡 Como tratar Missing Values?

Remover linhas: use df.dropna() — indicado quando a % de nulos é baixa (<5%).
Imputar pela média/mediana: df['col'].fillna(df['col'].median()) — para numéricas.
Imputar pela moda: df['col'].fillna(df['col'].mode()[0]) — para categóricas.
Imputar com valor fixo: df['col'].fillna('Desconhecido') — para textos.
Modelos de imputação: KNNImputer, IterativeImputer do sklearn — mais preciso.

3 Identifique e trate Outliers

Valores extremos podem distorcer toda a análise. Identifique-os visualmente e estatisticamente.

```
# Estatísticas descritivas completas
df.describe()

# Boxplot para visualizar outliers em todas as variáveis numéricas
import matplotlib.pyplot as plt

numericas = df.select_dtypes(include='number').columns
fig, axes = plt.subplots(nrows=1, ncols=len(numericas), figsize=(4*len(numericas), 5))

for ax, col in zip(axes, numericas):
    df.boxplot(column=col, ax=ax)
    ax.set_title(col)

plt.tight_layout()
plt.savefig('outliers_boxplot.png', dpi=150)
plt.show()

# Identificar outliers usando IQR (Interquartile Range)
def detectar_outliers_iqr(df, coluna):
    Q1 = df[coluna].quantile(0.25)
    Q3 = df[coluna].quantile(0.75)
    IQR = Q3 - Q1
    limite_inf = Q1 - 1.5 * IQR
    limite_sup = Q3 + 1.5 * IQR
    outliers = df[(df[coluna] < limite_inf) | (df[coluna] > limite_sup)]
    return outliers, limite_inf, limite_sup

outliers, lim_inf, lim_sup = detectar_outliers_iqr(df, 'sua_coluna')
print(f'Outliers encontrados: {len(outliers)}')
print(f'Intervalo esperado: [{lim_inf:.2f}, {lim_sup:.2f}]')
```

4 Verifique duplicatas e inconsistências

Registros duplicados podem inflar resultados e enviesar o modelo.

```
# Verificar duplicatas
print(f'Duplicatas: {df.duplicated().sum()}')

# Remover duplicatas
df = df.drop_duplicates()

# Verificar inconsistências em variáveis categóricas
for col in df.select_dtypes(include='object').columns:
    print(f'\n{col}: {df[col].nunique()} valores únicos')
    print(df[col].value_counts().head(10))

# Padronizar texto (remover espaços, colocar em minúsculo)
df['coluna_texto'] = df['coluna_texto'].str.strip().str.lower()

# Converter coluna de data
df['data'] = pd.to_datetime(df['data'], format='%d/%m/%Y', errors='coerce')
```

5 Normalize e padronize variáveis numéricas

Muitos algoritmos são sensíveis à escala dos dados. Normalize antes de modelar.

```
from sklearn.preprocessing import MinMaxScaler, StandardScaler

# MinMaxScaler: transforma para intervalo [0, 1]
scaler_mm = MinMaxScaler()
df_normalizado = scaler_mm.fit_transform(df[numericas])

# StandardScaler: média=0, desvio padrão=1 (Z-score)
scaler_std = StandardScaler()
df_padronizado = scaler_std.fit_transform(df[numericas])

# Quando usar cada um?
# MinMax: quando você sabe que os dados têm limites definidos
# StandardScaler: quando os dados têm distribuição aproximadamente normal
# Regressão logística, SVM e KNN são especialmente sensíveis à escala
```

4. Análise Univariada — Explorando Cada Variável

A análise univariada examina uma variável por vez. O objetivo é entender sua distribuição, identificar padrões, outliers e decidir se a variável é útil para o modelo.

4.1 Variáveis Numéricas

```
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np

# Histograma com KDE (curva de densidade)
plt.figure(figsize=(10, 5))
sns.histplot(df['sua_variavel'], kde=True, color='steelblue', bins=30)
plt.title('Distribuição de sua_variavel')
plt.xlabel('Valor')
plt.ylabel('Frequência')
plt.axvline(df['sua_variavel'].mean(), color='red', linestyle='--', label=f'Média: {df["sua_variavel"].mean():.2f}')
plt.axvline(df['sua_variavel'].median(), color='green', linestyle='--', label=f'Mediana: {df["sua_variavel"].median():.2f}')
plt.legend()
plt.tight_layout()
plt.savefig('histograma.png', dpi=150)
plt.show()

# Boxplot
plt.figure(figsize=(8, 4))
sns.boxplot(x=df['sua_variavel'], color='lightblue')
plt.title('Boxplot de sua_variavel')
plt.tight_layout()
plt.savefig('boxplot.png', dpi=150)
plt.show()
```

> 📌 **O que observar na análise univariada de variáveis numéricas**
>
> **Assimetria (skewness):** a cauda está para esquerda ou direita? Impacta algoritmos.
> **Curtose:** distribuição mais 'pontuda' ou 'achatada' que o normal?
> **Bimodalidade:** dois picos na distribuição indicam possíveis subgrupos.
> **Distância média-mediana:** se grande, a distribuição é assimétrica — prefira a mediana.
> **Outliers:** quantos estão fora do intervalo [Q1 - 1.5*IQR, Q3 + 1.5*IQR]?

4.2 Variáveis Categóricas

```
# Contagem de categorias
contagem = df['categoria'].value_counts()
print(contagem)

# Gráfico de barras horizontal (melhor para muitas categorias)
plt.figure(figsize=(10, 6))
contagem.plot(kind='barh', color='steelblue', edgecolor='white')
plt.title('Frequência por Categoria')
plt.xlabel('Contagem')
plt.tight_layout()
plt.savefig('barras_categorial.png', dpi=150)
plt.show()

# Adicionar rótulos nas barras
ax = contagem.plot(kind='barh', color='steelblue')
for p in ax.patches:
    ax.annotate(f'{int(p.get_width()):,}',
                (p.get_width() + 0.1, p.get_y() + p.get_height() / 2),
                ha='left', va='center', fontsize=10)

# Percentual por categoria
print((df['categoria'].value_counts(normalize=True) * 100).round(1))
```

5. Análise Bivariada e Matriz de Correlação

A análise bivariada examina como duas variáveis se relacionam entre si. É essencial para identificar quais variáveis têm poder preditivo e quais são redundantes (multicolinearidade).

5.1 Correlação de Pearson — Teoria

Coeficiente r	Interpretação	O que fazer
|r| > 0,9	Correlação muito forte	Avaliar multicolinearidade — remover uma das variáveis

Coeficiente r	Interpretação	O que fazer
|r| entre 0,7 e 0,9	Correlação forte	Investigar causalidade e contexto de negócio
|r| entre 0,5 e 0,7	Correlação moderada	Variável potencialmente útil para o modelo
|r| entre 0,3 e 0,5	Correlação fraca	Pode ser útil combinada com outras variáveis
|r| < 0,3	Correlação muito fraca ou nenhuma	Considerar remover do modelo (depende do contexto)

> ⚠️ **Atenção: Correlação não implica causalidade!**
> Um exemplo famoso: o consumo de sorvete e o número de afogamentos têm alta correlação.
> Mas sorvete não causa afogamento — ambos aumentam no verão (variável confundidora).
> Sempre interprete correlações dentro do contexto de negócio antes de tomar decisões.

5.2 Código — Matriz de Correlação Completa

```
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np

# Selecionar apenas variáveis numéricas
numericas = df.select_dtypes(include='number')

# Calcular matriz de correlação
corr_matrix = numericas.corr()

# Heatmap completo
plt.figure(figsize=(12, 10))
mask = np.triu(np.ones_like(corr_matrix, dtype=bool))  # Mostrar apenas triângulo inferior
sns.heatmap(
    corr_matrix,
    mask=mask,
    annot=True,
    fmt='.2f',
    cmap='RdYlBu_r',
    center=0,
    square=True,
    linewidths=0.5,
    cbar_kws={'shrink': 0.8},
    vmin=-1, vmax=1
)
plt.title('Matriz de Correlação de Pearson', fontsize=14, fontweight='bold')
plt.tight_layout()
plt.savefig('correlacao_heatmap.png', dpi=150, bbox_inches='tight')
plt.show()
```

```
# Identificar pares com alta correlação (|r| > 0.8)
alta_corr = []
for i in range(len(corr_matrix.columns)):
    for j in range(i+1, len(corr_matrix.columns)):
        if abs(corr_matrix.iloc[i, j]) > 0.8:
            alta_corr.append({
                'var1': corr_matrix.columns[i],
                'var2': corr_matrix.columns[j],
                'correlacao': round(corr_matrix.iloc[i, j], 3)
            })

import pandas as pd
print(pd.DataFrame(alta_corr).sort_values('correlacao', ascending=False))
```

5.3 Scatter Plot e Pairplot

```
# Scatter plot entre duas variáveis
plt.figure(figsize=(8, 6))
sns.scatterplot(
    data=df,
    x='variavel_x',
    y='variavel_y',
    hue='categoria',  # coloria por grupo (opcional)
    alpha=0.6
)
plt.title('Relação entre variavel_x e variavel_y')
plt.tight_layout()
plt.savefig('scatter.png', dpi=150)
plt.show()

# Pairplot — scatter matrix de todas as variáveis
# Ideal para datasets com até 8-10 variáveis numéricas
sns.pairplot(
    df[numericas.columns],
    diag_kind='kde',  # diagonal: densidade
    plot_kws={'alpha': 0.5}
)
plt.suptitle('Pairplot — Relações entre variáveis', y=1.02, fontsize=14)
plt.savefig('pairplot.png', dpi=150, bbox_inches='tight')
plt.show()
```

5.4 Comparação por Grupos

```
# Boxplot por grupo — compara distribuição entre categorias
plt.figure(figsize=(10, 6))
sns.boxplot(
    data=df,
    x='categoria',
    y='variavel_numerica',
    palette='Blues'
)
plt.title('Distribuição de variavel_numerica por categoria')
plt.xticks(rotation=45)
```

```
plt.tight_layout()
plt.savefig('boxplot_grupo.png', dpi=150)
plt.show()

# Violin plot — mostra densidade + boxplot
plt.figure(figsize=(10, 6))
sns.violinplot(
    data=df,
    x='categoria',
    y='variavel_numerica',
    palette='muted',
    inner='quartile'
)
plt.title('Violin Plot por Categoria')
plt.tight_layout()
plt.savefig('violinplot.png', dpi=150)
plt.show()

# Estatísticas por grupo
print(df.groupby('categoria')['variavel_numerica'].agg(['mean','median','std','count']))
```

6. Guia Rápido de Gráficos — Seaborn & Matplotlib

Tipo de Dado / Objetivo	Gráfico Ideal	Código Seaborn
Distribuição de 1 variável numérica	Histograma + KDE	sns.histplot(df['col'], kde=True)
Outliers e quartis de 1 variável	Boxplot	sns.boxplot(x=df['col'])
Distribuição detalhada com densidade	Violin Plot	sns.violinplot(x='cat', y='num', data=df)
Relação entre 2 numéricas	Scatter Plot	sns.scatterplot(x='x', y='y', data=df)
Tendência ao longo do tempo	Line Plot	sns.lineplot(x='data', y='valor', data=df)
Contagem de categorias	Barras	sns.countplot(x='categoria', data=df)
Média por grupo	Barras com erro	sns.barplot(x='cat', y='num', data=df)
Correlação entre múltiplas vars	Heatmap	sns.heatmap(df.corr(), annot=True)
Todas as relações de uma vez	Pairplot	sns.pairplot(df[numericas])
Proporção do todo	Pizza / Donut	df['col'].value_counts().plot(kind='pie')

6.1 Configurações de Estilo Profissional

```
import matplotlib.pyplot as plt
import seaborn as sns

# Paleta de cores neutra e profissional
sns.set_theme(style='whitegrid', palette='Blues_d', font_scale=1.1)

# Configuração global de figura
plt.rcParams.update({
    'figure.dpi': 150,
    'figure.figsize': (10, 6),
    'axes.titlesize': 14,
    'axes.titleweight': 'bold',
    'axes.labelsize': 12,
    'xtick.labelsize': 10,
    'ytick.labelsize': 10,
    'font.family': 'sans-serif',
})

# Salvar em alta resolução
plt.savefig('grafico.png', dpi=300, bbox_inches='tight', facecolor='white')

# Paletas recomendadas por contexto:
# Sequencial (uma cor): 'Blues', 'Greens', 'Oranges', 'viridis', 'plasma'
# Divergente (positivo/negativo): 'RdYlGn', 'RdBu', 'coolwarm'
# Categórico: 'tab10', 'Set2', 'husl', 'muted'
```

7. Prompts de IA para Apoiar sua Análise

Use estas sugestões de prompts no ChatGPT, Claude ou qualquer outra IA para acelerar e qualificar sua análise exploratória. Adapte os campos em colchetes [ ] para o seu projeto.

7.1 Entendimento dos Dados

🤖 Prompt 1 — Análise Inicial do Dataset

Você é um cientista de dados sênior. Tenho um dataset com as seguintes características:

- Tema: [descreva o que os dados representam]
- Número de linhas: [X] | Número de colunas: [Y]
- Colunas disponíveis: [liste os nomes e tipos]
- Objetivo do projeto: [o que você quer prever ou analisar]

Por favor, me ajude a:
1. Identificar quais colunas são mais relevantes para o objetivo
2. Sugerir quais variáveis podem ser descartadas de início
3. Listar possíveis problemas que podem existir nesses dados
4. Propor uma sequência lógica de análise exploratória

🤖 Prompt 2 — Interpretação de Estatísticas Descritivas

Analise as estatísticas descritivas abaixo do meu dataset e me explique:

[Cole aqui o output do df.describe()]

1. Quais variáveis têm distribuição assimétrica?
2. Existem indícios de outliers em alguma coluna?
3. Quais colunas apresentam variação muito baixa (possível constante)?
4. O que a diferença entre média e mediana indica em cada coluna?
5. Quais transformações você recomenda aplicar antes da modelagem?

7.2 Tratamento de Dados

🤖 Prompt 3 — Estratégia para Valores Ausentes

Tenho um dataset sobre [tema] com os seguintes campos com dados ausentes:

[Cole aqui o resultado de df.isnull().sum()]

Contexto de negócio: [descreva brevemente o domínio]

Para cada coluna com missing, me recomende:
1. A melhor estratégia de tratamento (remoção, imputação, etc.)
2. O risco de cada abordagem
3. O código Python correspondente usando pandas ou sklearn
Justifique sua recomendação com base no contexto de negócio.

🤖 Prompt 4 — Detecção e Tratamento de Outliers

Tenho os seguintes boxplots/estatísticas descritivas do meu dataset:
[descreva ou cole os dados]

O projeto é sobre [tema]. Me ajude a:

1. Identificar quais outliers provavelmente são erros de dados vs. valores reais
2. Para cada caso, sugerir a melhor abordagem de tratamento
3. Escrever o código Python para aplicar o tratamento recomendado
4. Explicar como os outliers podem impactar modelos de ML se não tratados

7.3 Visualização e Interpretação

🤖 **Prompt 5 — Geração de Código para Visualizações**

Preciso criar visualizações de dados exploratórias para um dataset sobre [tema].
As colunas disponíveis são:
- Numéricas: [liste]
- Categóricas: [liste]
- Temporais (datas): [liste]
- Variável alvo (target): [nome da coluna]

Crie para mim código Python completo usando matplotlib e seaborn para:
1. Distribuição de cada variável numérica (histograma + boxplot lado a lado)
2. Contagem de cada variável categórica (barras horizontais)
3. Correlação com a variável alvo para cada variável numérica
4. Matriz de correlação completa com heatmap
Salve cada gráfico como arquivo PNG em alta resolução (300 dpi).

🤖 **Prompt 6 — Interpretação da Matriz de Correlação**

Analisando a matriz de correlação do meu dataset sobre [tema], os principais coeficientes de Pearson são:

[Cole ou descreva os valores de correlação entre as variáveis]

Me ajude a:
1. Identificar quais pares de variáveis têm multicolinearidade problemática
2. Interpretar o que cada correlação significa no contexto de [tema]
3. Recomendar quais variáveis devo remover para evitar redundância
4. Sugerir se alguma transformação (log, quadrado) poderia melhorar relações
5. Identificar quais variáveis têm mais potencial preditivo sobre [target]

7.4 Criação do Manual de Identidade Visual (MIV)

🤖 **Prompt 7 — Criar MIV para o Projeto**

Aja como um designer visual especializado em Data Science.
Crie um Manual de Identidade Visual (MIV) completo para o meu projeto com as seguintes informações:

- Nome do projeto: [nome]
- Tema / domínio: [ex: saúde, finanças, educação, meio ambiente]
- Público-alvo das apresentações: [ex: gestores, técnicos, acadêmicos]
- Tom desejado: [ex: profissional e sério / inovador e moderno]

O MIV deve incluir:
1. Paleta de cores primária e secundária (com códigos HEX)
2. Tipografia recomendada (fonte principal e alternativa)
3. Estilo de gráficos (cores, bordas, grades, rótulos)
4. Padrão de títulos e legendas
5. Código Python (matplotlib/seaborn) para aplicar esse estilo globalmente

🤖 **Prompt 8 — Narrativa para Apresentação dos Dados**

Tenho os seguintes achados da minha análise exploratória sobre [tema]:

[Descreva os principais insights que você encontrou]

Meu público é: [descreva: ex. diretores de empresa, professores, bancas acadêmicas]

Me ajude a construir uma narrativa para apresentar esses dados. Quero que a apresentação:
1. Comece com uma pergunta ou dado surpreendente para engajar o público
2. Conduza o público pelos dados de forma lógica e progressiva
3. Destaque os 3 principais insights com linguagem acessível
4. Termine com uma conclusão clara e chamada para ação
5. Sugira quais gráficos usar em cada slide e como organizá-los

8. Bases de Dados para Praticar

Além dos dados do seu projeto, praticar com bases conhecidas é fundamental para desenvolver repertório analítico. Veja as principais:

8.1 Datasets Clássicos para Iniciantes

Dataset	Descrição	Onde Encontrar
Titanic	Sobreviventes do Titanic. Clássico para classificação e EDA.	Kaggle.com/datasets/titanic
Iris	Medidas de flores. Ideal para clustering e classificação.	sklearn.datasets.load_iris()
Wine Quality	Qualidade de vinhos por características físico-químicas.	UCI ML Repository
Boston Housing	Preços de imóveis com 13 variáveis explicativas.	sklearn.datasets.load_boston() (alternativas no Kaggle)
Heart Disease	Diagnóstico de doença cardíaca com 13 atributos clínicos.	UCI ML Repository / Kaggle
Customer Churn	Churn de clientes em telecom. Problema de desbalanceamento.	Kaggle — Telco Customer Churn

8.2 Bases de Dados Brasileiras Públicas

Base	Descrição	Fonte
RAIS	Relação Anual de Informações Sociais — mercado de trabalho formal.	pdet.mte.gov.br
CAGED	Admissões e demissões mensais por empresa e setor.	pdet.mte.gov.br
IBGE Cidades	Dados demográficos, econômicos e sociais por município.	ibge.gov.br/cidades
DataSUS	Dados de saúde, internações, mortalidade e epidemiologia.	datasus.saude.gov.br
INMET	Dados climáticos e meteorológicos históricos do Brasil.	inmet.gov.br
Portal Dados Abertos RS	Dados do governo do Rio Grande do Sul por temática.	dados.rs.gov.br
Basedosdados.io	Hub centralizado de dados públicos brasileiros tratados.	basedosdados.io

> 💡 **Dica — Enriqueça seu projeto com dados externos**
>
> Como mencionado na aula: fique à vontade para buscar dados externos que se correlacionem com o tema do seu projeto. Exemplos de correlações interessantes:
>
> **Projeto de finanças:** cruzar com dados de presidências, políticas monetárias ou PIB.
> **Projeto de saúde:** cruzar com dados climáticos, socioeconômicos ou de infraestrutura.
> **Projeto de varejo:** cruzar com dados de sazonalidade, feriados ou renda por região.
>
> Dados externos trazem contexto e enriquecem a narrativa da sua análise.

9. Ferramentas e Recursos Essenciais

9.1 Bibliotecas Python para EDA

Biblioteca	Para que serve	Instalação
pandas	Manipulação e análise de dados tabulares. Base de tudo.	pip install pandas
numpy	Operações numéricas e matriciais de alta performance.	pip install numpy
matplotlib	Criação de gráficos estáticos de baixo nível (alta customização).	pip install matplotlib
seaborn	Gráficos estatísticos elegantes sobre matplotlib.	pip install seaborn
plotly	Gráficos interativos para dashboards e apresentações web.	pip install plotly
scipy	Testes estatísticos (t-test, ANOVA, chi-quadrado, etc.).	pip install scipy
ydata-profiling	Gera relatório completo de EDA com um único comando!	pip install ydata-profiling
missingno	Visualizações especializadas para valores ausentes.	pip install missingno
sweetviz	Relatório visual comparativo de datasets com uma linha.	pip install sweetviz

🚀 **Dica de ouro — EDA Automatizada em 1 linha!**

O ydata-profiling gera um relatório HTML completo e interativo do seu dataset, incluindo distribuições, correlações, missing values e alertas automáticos:

```
from ydata_profiling import ProfileReport
profile = ProfileReport(df, title='EDA — Meu Projeto', explorative=True)
profile.to_file('relatorio_eda.html')
```

Use para ter uma visão geral rápida antes de aprofundar a análise manualmente.

9.2 Sites e Recursos Indicados na Aula

Recurso	O que oferece	Link
From Data to Viz	Selecione seu tipo de dado e veja o gráfico ideal com código Python incluído.	data-to-viz.com
Statista	Galeria de gráficos profissionais para inspiração visual.	statista.com
Tableau Public	Dashboards públicos para inspiração e modelos de visualização.	public.tableau.com
Kaggle Learn	Cursos gratuitos de EDA, pandas, visualização e ML.	kaggle.com/learn
Python Graph Gallery	Galeria completa de gráficos com código Python pronto.	python-graph-gallery.com
Seaborn Gallery	Todos os tipos de gráficos do seaborn com exemplos e código.	seaborn.pydata.org/examples
Google Colab	Jupyter Notebook na nuvem, gratuito, com GPU disponível.	colab.research.google.com

10. Boas Práticas de Visualização de Dados

10.1 O Princípio Fundamental

📌 **Interpretação ANTES do Gráfico**

Errado: criar gráficos genéricos e tentar extrair uma história deles depois.
Certo: definir o que você quer comunicar → escolher o gráfico adequado → criar.

O gráfico é um AUXÍLIO VISUAL ao que você já sabe — nunca o ponto de partida.
Isso vale para TCC, seminário, relatório, dashboard e apresentação para clientes.

10.2 Regras de Ouro do Design

- **Menos é mais:** retire tudo que não contribui para a mensagem (gridlines excessivas, bordas, 3D desnecessário).
- **Uma cor = um significado:** use cores de forma consistente ao longo de toda a apresentação.
- **Escolha o gráfico certo:** cada tipo de dado tem um gráfico ideal — não use pizza para comparar 10 categorias.
- **Rótulos e títulos claros:** o gráfico deve ser autoexplicativo sem precisar da sua voz.
- **Alta resolução:** sempre exporte com dpi=300 para impressão ou apresentações.
- **Teste com alguém:** se a pessoa não entender o gráfico sozinha em 5 segundos, simplifique.
- **Padronize o estilo:** use as mesmas fontes, tamanhos e cores em todos os gráficos do projeto.

10.3 O que NUNCA fazer

Erro Comum	Por que é problemático	Como corrigir
Gráfico 3D sem necessidade	Distorce percepção de proporções e dificulta leitura.	Use 2D sempre. 3D apenas para dados espaciais reais.
Pizza com muitas fatias	Difícil comparar tamanhos com >5 categorias.	Use barras horizontais ordenadas por frequência.
Eixo Y truncado	Exagera diferenças e pode enganar o público.	Sempre comece o eixo Y em zero para barras.
Cores sem significado	Distrai o leitor e não comunica informação extra.	Use escala de uma cor ou destaque apenas o dado importante.
Informação demais em um gráfico	O leitor não sabe onde focar.	Divida em múltiplos gráficos simples.

Erro Comum	Por que é problemático	Como corrigir
Colar gráfico exploratório na apresentação	Gráficos genéricos do pandas/matplotlib parecem rasunho.	Recrie os gráficos finais com estilo e título adequados.

11. Checklist — Análise Exploratória para a Próxima Aula

Use este checklist para garantir que você cobriu todos os pontos essenciais antes de apresentar sua análise ao grupo.

✅ Fase 1 — Preparação dos Dados

- ☐ Carreguei o dataset e verifiquei shape, dtypes e head()
- ☐ Identifiquei e documentei o significado de cada coluna
- ☐ Verifiquei o cabeçalho e o delimitador do arquivo
- ☐ Analisei a % de valores ausentes por coluna
- ☐ Defini e apliquei a estratégia de tratamento de missing values
- ☐ Identifiquei e documentei os outliers encontrados
- ☐ Decidi o que fazer com cada outlier (manter, remover ou transformar)
- ☐ Verifiquei e removi duplicatas
- ☐ Padronizei tipos de dados (datas, textos, números)

✅ Fase 2 — Análise Univariada

- ☐ Gerei histograma + boxplot para cada variável numérica
- ☐ Identifiquei a distribuição de cada variável (normal, assimétrica, bimodal?)
- ☐ Gerei contagem/percentual para cada variável categórica
- ☐ Documentei os insights mais relevantes de cada variável

✅ Fase 3 — Análise Bivariada

- ☐ Gerei a matriz de correlação de Pearson com heatmap
- ☐ Identifiquei pares com alta correlação ($|r| > 0,7$)
- ☐ Avaliei o risco de multicolinearidade
- ☐ Criei scatter plots para as relações mais importantes
- ☐ Comparei distribuições por grupo (boxplot/violin por categoria)

✅ Fase 4 — Apresentação

- ☐ Defini uma narrativa clara: o que os dados contam?
- ☐ Recriei os gráficos finais com estilo visual padronizado
- ☐ Adicionei títulos, rótulos e fontes claros em todos os gráficos
- ☐ Testei os gráficos com um colega (ele entendeu sem explicação?)
- ☐ Preparei pelo menos 3 insights principais para apresentar ao grupo
- ☐ (Bônus) Busquei dados externos para enriquecer a análise

12. Glossário de Termos

Termo	Definição
EDA	Exploratory Data Analysis — análise exploratória de dados antes da modelagem.
Missing Values	Valores ausentes numa base de dados. Representados por NaN, null ou vazio.
Outlier	Valor extremo que se distancia significativamente dos demais. Pode ser erro ou sinal.
IQR	Interquartile Range — intervalo entre Q1 (25%) e Q3 (75%). Usado para detectar outliers.
Upsampling / SMOTE	Técnica para criar registros sintéticos da classe minoritária em dados desbalanceados.
Correlação de Pearson	Coeficiente que mede relação linear entre duas variáveis. Varia de -1 a +1.
Multicolinearidade	Alta correlação entre variáveis preditoras — pode prejudicar interpretação do modelo.
Skewness	Assimetria da distribuição. Positiva = cauda à direita. Negativa = cauda à esquerda.
Kurtosis	Medida de 'pontualidade' da distribuição em relação à normal (gaussiana).
Normalização	Transformar variáveis para uma escala comum (ex: [0,1] com MinMaxScaler).
Padronização	Transformar para média=0 e desvio padrão=1 (Z-score com StandardScaler).
KDE	Kernel Density Estimation — estimativa suave da distribuição de probabilidade.
Heatmap	Visualização matricial que usa cores para representar intensidade de valores.
Pairplot	Matriz de scatter plots de todas as combinações de variáveis numéricas.
MIV	Manual de Identidade Visual — padroniza cores, fontes e estilos visuais do projeto.
RAIS	Relação Anual de Informações Sociais — dados do mercado formal de trabalho brasileiro.
CAGED	Cadastro Geral de Empregados e Desempregados — registro mensal de movimentações.
Delimitador	Caractere que separa campos em arquivos de dados (vírgula em CSV, ponto e vírgula, tab).

13. Tarefa para a Próxima Aula

🎯 **O que deve ser apresentado**

Realize a Análise Exploratória de Dados (EDA) completa do projeto do seu grupo.
Na próxima aula presencial, cada grupo apresentará seus resultados e receberá feedback.

Entregáveis mínimos:

1. Análise univariada de todas as variáveis (com gráficos)
2. Identificação e tratamento de missing values e outliers
3. Matriz de correlação completa com interpretação
4. Pelo menos 3 insights relevantes sobre os dados
5. Visualizações padronizadas (mesma paleta de cores e estilo)

Bônus (diferencial):

+ Dados externos incorporados à análise
+ Narrativa preparada para apresentar os achados
+ MIV aplicado aos gráficos do projeto

💬 **Sobre a Apresentação**

Não existe certo ou errado nesse momento — o objetivo é exercitar o olhar analítico.
Mesmo que sua análise ainda esteja incompleta, traga o que você explorou e as dúvidas que surgiram. O grupo aprende junto nesse momento.

Dúvidas? Mande mensagem no grupo do WhatsApp ou pelo Moodle.
Boa sorte e bom trabalho! 🚀

14. Referências Bibliográficas

- TUFTE, Edward R. The Visual Display of Quantitative Information. Graphics Press, 2001.
- WILKE, Claus O. Fundamentals of Data Visualization. O'Reilly, 2019. clauswilke.com/dataviz
- MCKINNEY, Wes. Python for Data Analysis. O'Reilly, 2022.
- KNAFLIC, Cole N. Storytelling with Data. Wiley, 2015.
- From Data to Viz — data-to-viz.com
- Seaborn Documentation — seaborn.pydata.org
- ydata-profiling — docs.profiling.ydata.ai