ROTEIRO DE APRESENTAÇÃO

Sugestão de fala para cerca de 8–10 minutos + perguntas dos avaliadores

Mensagem para abrir (25–35 segundos)

“O objetivo não era apenas acertar uma classificação. Queríamos criar um alerta antecipado capaz de reduzir o tempo em que o forno não está operando na condição ideal. Trabalhamos com mais de 1.700 corridas, modelamos os dois carregamentos separadamente e testamos os algoritmos em um período futuro.”

Slide 1 — Problema e custo (~1 min)

“Carga alta ocorre quando o material impede o fechamento correto da tampa. Nossa base tem 1.799 corridas, 541 com carga alta — 30,1%. A soma de paradas registrada nesse conjunto ultrapassa 36 horas. Escolhemos prever por cestão, porque a decisão é diferente no primeiro e no segundo carregamento.”

Se questionarem: Domínio: 541/1.799 é taxa por corrida, NÃO por cestão. O total de parada está em minutos acumulados da amostra; não é economia prometida.

Slide 2 — Dados, momentos e engenharia (~1min15s)

“Partimos de dados hierárquicos corrida → carregamento → camada e calculamos features físicas, de composição, de ordem e do histórico. O volume estimado é soma do peso em toneladas dividido pela densidade em toneladas por metro cúbico. Também usamos HHI de concentração e proporção de sucata pesada. O resultado do primeiro cestão só entra no modelo do segundo, pois nesse momento já é conhecido.”

Se questionarem: Domínio: excluímos de propósito duração de paradas e presença do gusa líquido (carregamento 3) para não vazar informação futura. O tempo de montagem só é válido se o modelo atuar após a composição do cestão.

Slide 3 — Método de validação e seleção (~1min15s)

“Separamos corridas cronologicamente: treinamento, validação e um teste futuro reservado. No treino, comparamos variáveis usando Mann–Whitney com ajustes BH/Holm, removemos redundância de correlação acima de 0,9 e avaliamos RFE e L1. Treinamos logística, Random Forest, Gradient Boosting e XGBoost. O limiar foi calibrado na validação, priorizando F2 com orçamento de até 35% de alertas.”

Se questionarem: Domínio: F2 dá mais peso ao recall porque falso negativo perde uma oportunidade de evitar parada. Restringimos alarmes porque um modelo que alerta tudo é inoperante.

Slide 4 — Resultado dos modelos (~1min30s)

“Random Forest teve o melhor F2 na validação dos dois cestões. No teste futuro, no C1 o recall foi 84,6% e a precisão 33,3%. No C2, 80,6% e 45,5%. Em números: 22 de 26 e 25 de 31 eventos detectados, respectivamente. Precisamos levar a sério 44 e 30 falsos alarmes.”

Se questionarem: Domínio: ROC-AUC mede ranqueamento global, PR-AUC é especialmente informativa com eventos menos frequentes, F2 combina precisão e recall com mais peso para recall. Teste final intocado evita ajuste oportunista.

Slide 5 — Variáveis e achados da indústria (~1min15s)

“A proporção de materiais pesados apareceu entre os sinais de maior importância, especialmente no segundo cestão. No C2, o evento registrado no C1 e a taxa recente de carga alta também ajudaram. Isso contrasta com a expectativa de usar só o volume. A importância foi medida por permutação na validação, e significa capacidade de prever, não prova de causalidade.”

Se questionarem: Domínio: algumas variáveis são correlacionadas, então a importância individual pode diminuir mesmo quando a família é valiosa. O RFE selecionou 14 variáveis, mas o melhor desempenho veio do conjunto de 56/59 no RF.

Slide 6 — Feriados e testes de hipótese (~1min15s)

“Nossa hipótese foi que feriados poderiam influenciar a incidência. A taxa observada foi 39,7% em 68 corridas de feriados contra 29,6% em 1.728 outras. Mas o Fisher resultou p=0,080 e um teste mais robusto, permutando dias dentro de mês e tipo de dia, deu p=0,300. Ou seja, não rejeitamos a igualdade. A conclusão muda com o fuso, então o calendário do sistema precisa ser confirmado.”

Se questionarem: Domínio: a amostra tem só 12 dias de feriado e não há feriados no holdout. Não vender associação espúria como evidência. Corpus Christi e Santo Antônio são feriados municipais de Juiz de Fora.

Slide 7 — Plano de valor e próximos passos (~1min30s)

“No teste, os eventos corretamente sinalizados somavam cerca de 157 minutos de parada. Isso é uma oportunidade teórica, não economia realizada. Propomos piloto em modo sombra, medindo quais alertas têm ação viável, custo do falso positivo e ganho de minutos de forno. Também monitoraremos a mudança de composição, porque o teste de drift mostrou diferenças grandes entre os períodos.”

Se questionarem: Domínio: não dizer que 157 minutos serão poupados. Com 121 alertas, mesmo uma intervenção de 1 minuto por alerta pode inviabilizar benefícios caso poucos eventos sejam evitáveis.

Perguntas prováveis e respostas curtas

Por que dois modelos? O cesto 2 tem distribuição de massa e disponibilidade de contexto diferentes; um modelo único confundiria regimes e não poderia usar o desfecho de C1 antes do tempo.

Por que Random Forest? Obteve maior F2 com limite de alarmes na validação e capturou não linearidade/interações sem precisar impor forma funcional linear.

Por que não usar acurácia? Uma classe positiva minoritária faria um modelo que prevê quase sempre zero parecer bom. Recall, precisão, PR-AUC e F2 revelam o custo operacional.

Existe vazamento de dados? Retiramos respostas e durações, gusa do terceiro carregamento, preservamos split temporal e usamos histórico deslocado. Ainda é necessário confirmar disponibilidade temporal de cada feature com a planta.

Feriado influencia? A taxa observada difere, mas testes que respeitam dia, calendário e fuso não comprovam associação robusta. Não há feriados no teste futuro.

A composição causa carga alta? Mostramos associação e poder preditivo, não causalidade. Uma ação operacional e um teste prospectivo são necessários.

Quanto a empresa ganha? Ainda não é possível quantificar em R$. Temos 157 min associados a eventos detectados no holdout; o ganho líquido depende de prevenção efetiva e custo de cada alerta.

O que é drift? Mudança do processo ou da distribuição de insumos ao longo do tempo. Detectamos diferença grande na proporção de material pesado entre treino e teste.

Como funciona o F2? É média harmônica ponderada de precisão e recall com recall valendo quatro vezes mais no componente de penalização; não dispensa medir falsos alarmes.

Se o modelo errar o que acontece? Falso negativo perde oportunidade de agir; falso positivo pode atrasar carregamento. Limiar é uma decisão econômica, não uma verdade estatística.